

**UNIVERSIDADE DE SÃO PAULO
ESCOLA DE ENGENHARIA DE SÃO CARLOS**

Vinícius Moraes Andreghetti

**Filtragem de Ruído usando Filtros de Duplo Domínio e
Descritores de Textura**

São Carlos

2020

Vinícius Moraes Andreghetti

Filtragem de Ruído usando Filtros de Duplo Domínio e Descritores de Textura

Monografia apresentada ao Curso de Engenharia Elétrica com Ênfase em Eletrônica, da Escola de Engenharia de São Carlos da Universidade de São Paulo, como parte dos requisitos para obtenção do título de Engenheiro Eletricista.

Orientador: Prof. Dr. Marcelo Andrade da Costa Vieira

**São Carlos
2020**

ERRATA

Modelo de Errata:

ANDREGHETTI, V. **Filtragem de Ruído usando Filtros de Duplo Domínio e Descritores de Textura**. 2020. 55p. Monografia (Trabalho de Conclusão de Curso) - Escola de Engenharia de São Carlos, Universidade de São Paulo, São Carlos, 2020.

ERRATA

Folha	Linha	Onde se lê	Leia-se
1	10	auto-conclavo	autoconclavo

Folha de aprovação em conformidade
com o padrão definido
pela Unidade.

No presente modelo consta como
folhadeaprovacao.pdf

*Este trabalho é dedicado aos alunos da USP, como uma contribuição
das Bibliotecas do Campus USP de São Carlos para o desenvolvimento
e disseminação da pesquisa científica da Universidade.*

AGRADECIMENTOS

A motivação para o desenvolvimento da classe USPSC e dos modelos de trabalhos acadêmicos foi decorrente de solicitações de usuários das Bibliotecas do Campus USP de São Carlos. A versão 2.0 do Pacote USPSC é composto da **Classe USPSC**, do **Modelo para TCC em L^AT_EX utilizando a classe USPSC** e do **Modelo para teses e dissertações em L^AT_EX utilizando a classe USPSC**.

O Modelo para TCC está disponível inicialmente apenas para EESC e será estendido às demais Unidades de Ensino do Campus USP de São Carlos a medida que as mesmas definirem seus padrões.

O Grupo desenvolvedor do Pacote USPSC agradece especialmente ao Luis Olmes, doutorando do Instituto de Ciências Matemáticas e de Computação (ICMC) da Universidade de São Paulo (USP), pelas primeiras orientações sobre o L^AT_EX.

Agradecemos ao Lauro César Araujo pelo desenvolvimento da classe abnT_EX2, modelos canônicos e tantas outras contribuições que nos permitiu o desenvolvimento da classe USPSC e seus modelos.

Os nossos agradecimentos aos integrantes do primeiro projeto abnT_EX: Gerald Weber, Miguel Frasson, Leslie H. Watter, Bruno Parente Lima, Flávio de Vasconcellos Corrêa, Otavio Real Salvador, Renato Machnievscz, e a todos que contribuíram para que a produção de trabalhos acadêmicos em conformidade com as normas ABNT com L^AT_EX fosse possível.

Agradecemos ao grupo de usuários *latex-br* <<http://groups.google.com/group/latex-br>>, aos integrantes do grupo *abnT_EX2* <<http://groups.google.com/group/abntex2>> e <<http://www.abntex.net.br>> que contribuem para a evolução do abnT_EX2.

*“O estudo, a busca da verdade e da beleza são domínios
em que nos é consentido sermos crianças por toda a vida.”*

Albert Einstein

RESUMO

ANDREGHETTI, V. **Filtragem de Ruído usando Filtros de Duplo Domínio e Descritores de Textura**. 2020. 55p. Monografia (Trabalho de Conclusão de Curso) - Escola de Engenharia de São Carlos, Universidade de São Paulo, São Carlos, 2020.

Palavras-chave:

ABSTRACT

ANDREGHETTI, V. **Noisy Filtering using Dual Domain Filtering and Texture**

Descriptors. 2020. 55p. Monografia (Trabalho de Conclusão de Curso) - Escola de Engenharia de São Carlos, Universidade de São Paulo, São Carlos, 2020.

This is the english abstract.

Keywords: LaTeX. abnTeX. USPSC class. Text editoration. Standardization of documentation. Academic work. Thesis. Dissertation. Documents (development). Electronic documents.

LISTA DE FIGURAS

Figura 1 – Ilustração de <i>Block-matching</i> para três diferentes fragmentos de imagem. Em vermelho marcados com um “R”, são os fragmentos-referência; em azul, os respectivos fragmentos semelhantes.	36
Figura 2 – Imagens utilizadas para validação dos filtros propostos.	41
Figura 3 – Detalhe em HWC001-120 para comparação entre métodos de filtragem, com $\sigma = 25$	44
Figura 4 – Detalhe em HWC002-120 para comparação entre métodos de filtragem, com $\sigma = 25$	44
Figura 5 – Detalhe em HWC011-120 para comparação entre métodos de filtragem, com $\sigma = 25$	44
Figura 6 – Detalhe em HWC012-120 para comparação entre métodos de filtragem, com $\sigma = 25$	44
Figura 7 – Detalhe em HWC001-120 para comparação entre métodos de filtragem, com $\sigma = 100$	44
Figura 8 – Detalhe em HWC002-120 para comparação entre métodos de filtragem, com $\sigma = 100$	45
Figura 9 – Detalhe em HWC011-120 para comparação entre métodos de filtragem, com $\sigma = 100$	45
Figura 10 – Detalhe em HWC012-120 para comparação entre métodos de filtragem, com $\sigma = 100$	45

LISTA DE TABELAS

Tabela 1 – Valores de PSNR médio para aquisições em HWC001-120. Os maiores valores para cada tipo de ruído estão em negrito.	45
Tabela 2 – Valores de PSNR médio para aquisições em HWC002-120. Os maiores valores para cada tipo de ruído estão em negrito.	46
Tabela 3 – Valores de PSNR médio para aquisições em HWC011-120. Os maiores valores para cada tipo de ruído estão em negrito.	46
Tabela 4 – Valores de PSNR médio para aquisições em HWC012-120. Os maiores valores para cada tipo de ruído estão em negrito.	46

LISTA DE QUADROS

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
abnTeX	ABsurdas Normas para TeX
EESC	Escola de Engenharia de São Carlos
IAU	Instituto de Arquitetura e Urbanismo
IBGE	Instituto Brasileiro de Geografia e Estatística
ICMC	Instituto de Ciências Matemáticas e de Computação
IFSC	Instituto de Física de São Carlos
IQSC	Instituto de Química de São Carlos
PDF	Portable Document Format
TCC	Trabalho de Conclusão de Curso
USP	Universidade de São Paulo
USPSC	Campus USP de São Carlos

LISTA DE SÍMBOLOS

Γ	Letra grega Gama
Λ	Lambda
ζ	Letra grega minúscula zeta
\in	Pertence

SUMÁRIO

1	INTRODUÇÃO	29
1.1	Motivação	29
1.2	Justificativa	29
1.3	Objetivos	29
2	EMBASAMENTO TEÓRICO	31
2.1	Textura em Imagens	31
2.2	Aquisição de Imagens Digitais	31
2.2.1	Digitalização	31
2.2.1.1	Detector finito	31
2.2.1.2	Eletrônica	31
2.2.1.3	Conversor A/D	31
2.2.1.4	Ruído	31
2.2.2	Degradação	31
2.2.2.1	Função de espalhamento de ponto (PSF)	31
2.2.2.2	Ruído	31
2.3	Restauração de Imagens	31
2.3.1	Degradação somente por ruído	31
2.4	Filtros de Ruídos	31
2.4.1	Filtro de Wiener	31
2.4.2	Filtro Bilateral	31
2.4.3	<i>Non-Local Means</i>	32
2.4.4	<i>Non-Local Dual Image Denoising</i>	32
2.4.5	Filtro de <i>Wavelet</i>	32
2.4.6	<i>Dual Domain Image Denoising</i>	32
2.4.6.1	Filtragem no Domínio Espacial: Filtro Bilateral	33
2.4.6.2	Filtragem no Domínio da Transformada	33
2.4.6.3	Domínio da Frequência: Wavelet Shrinkage	34
2.4.7	<i>Data Adaptative Dual Domain Denoising</i>	34
2.4.8	<i>Block Matching and 3D Filtering</i>	35
2.4.8.1	<i>Block-matching</i>	36
2.4.8.2	<i>Collaborative Filtering e shrinkage no domínio da transformada</i>	36
2.5	Descritores de Textura	37
2.5.1	Haralick (GLCM)	37
2.5.2	<i>Local Binary Pattern</i>	37
2.5.3	<i>Local Mapped Pattern</i>	38

2.6	Combinações de Filtros de Ruído e Descritores de Textura	38
2.6.1	NLM + LBP	38
2.6.1.1	<i>Non-local Means</i>	39
2.6.1.2	<i>Local Binary Pattern (LBP)</i>	39
2.6.1.3	<i>Método Proposto – Utilização de função de pesos baseada em LBP</i> .	39
2.7	Métricas de Avaliação	39
2.7.1	<i>Peak of Signal-to-Noise-Ratio</i>	39
3	MATERIAIS E MÉTODOS	41
3.1	Banco de Imagens	41
3.2	Validação de Métodos da Literatura	41
3.2.1	<i>DA3D - Detalhes de Implementação</i>	42
3.3	Próximos Passos	42
4	RESULTADOS E DISCUSSÃO	43
4.1	Validação de Métodos da Literatura	43
4.1.1	Imagens Obtidas	43
4.1.2	Comparação de PSNR	43
	REFERÊNCIAS	47
	APÊNDICES	49
	APÊNDICE A – EXEMPLO DE APÊNDICE	51
	ANEXOS	53
	ANEXO A – EXEMPLO DE ANEXO	55

1 INTRODUÇÃO

1.1 Motivação

- Comentar sobre textura
- Aquisição e ruído
- Pré-processamento: filtragem de ruído

1.2 Justificativa

- Em geral, filtros de ruído podem ser:
 - Espacial – preserva borda, remove textura
 - Frequência – preserva textura, remove bora
- Duplo domínio – abordagem para aproveitar a melhor característica de cada um dos domínios

1.3 Objetivos

Estrutura básica do projeto

- **Tema delimitado:** Tratamento de Ruído Quântico em Imagens Radiológicas Digitais
- **Problema de Pesquisa:** Combinação de Filtros de Duplo Domínio e Descritores de Textura para diminuição de ruído
- **Objetivo Geral:** Definir uma combinação de métodos de filtragem em duplo domínio e descritores de textura que melhorem o tratamento de ruído, possibilitando obter imagens de maior qualidade com doses de radiação iguais ou menores ao que utiliza atualmente
- **Objetivos Específicos:**
 1. Validação de métodos de filtragem de duplo domínio através de métricas objetivas de qualidade de filtragem de ruído;
 - a) Implementação dos códigos de cada filtro (BM3D, LBP+NLM, DDID, DA3D) para filtragem de imagens-padrão
 - b) Comparação entre os métodos através de métricas quantitativas de filtragem de ruído e preservação de texturas (PSNR, SSIM, MSE)

2. Determinar, dentre as combinações entre métodos de filtragem de duplo domínio e descritores de textura, qual a melhor combinação que combine eliminação de ruído e preservação de texturas, através de testes utilizando imagens-padrão, imagens de *phantoms* e imagens clínicas;
 - a) Determinar, dentre as combinações entre métodos de filtragem de duplo domínio e descritores de textura, qual a melhor combinação para eliminação de ruído;
 - b) Determinar, dentre as combinações entre métodos de filtragem de duplo domínio e descritores de textura, qual a melhor combinação para preservação de texturas;
 - c) Determinar, dentre as combinações entre métodos de filtragem de duplo domínio e descritores de textura, qual a combinação que melhor equilibra eliminação de ruído e preservação de texturas;
3. Pesquisa e implementação de métodos de descritores de textura (e outros classificadores)

2 EMBASAMENTO TEÓRICO

2.1 Textura em Imagens

2.2 Aquisição de Imagens Digitais

2.2.1 Digitalização

2.2.1.1 Detector finito

2.2.1.2 Eletrônica

2.2.1.3 Conversor A/D

2.2.1.4 Ruído

2.2.2 Degradação

2.2.2.1 Função de espalhamento de ponto (PSF)

2.2.2.2 Ruído

2.3 Restauração de Imagens

2.3.1 Degradação somente por ruído

2.4 Filtros de Ruídos

2.4.1 Filtro de Wiener

2.4.2 Filtro Bilateral

O filtro é definido em uma vizinhança \mathcal{N}_p centrada em p com raio r . Tanto a imagem ruidosa quanto a imagem guia são filtradas paralelamente, obtendo-se duas imagens filtradas de alto contraste, a fim de se poder guiar tanto os processos em ambos os domínios (Knaus; Zwicker, 2013). As imagens obtidas neste processo são definidas por:

$$\tilde{g}_p = \frac{\sum_{q \in \mathcal{N}_p} (k_{p,q} \cdot g_q)}{\sum_{q \in \mathcal{N}_p} (k_{p,q})} \quad (2.1)$$

$$\tilde{s}_p = \frac{\sum_{q \in \mathcal{N}_p} (k_{p,q} \cdot y_q)}{\sum_{q \in \mathcal{N}_p} (k_{p,q})} \quad (2.2)$$

onde $k_{p,q}$ é o *kernel* bilateral, dado por:

$$k_{p,q} = e^{-\frac{|p-q|^2}{2 \cdot \sigma_s^2}} \cdot e^{-\frac{(g_p - g_q)^2}{\gamma_r \cdot \sigma^2}} \quad (2.3)$$

sendo σ_s o peso relativo ao *kernel* espacial, isto é, $|p - q|$, e γ_r , o peso relativo ao *kernel* fotométrico, ou seja $(g_p - g_q)$.

2.4.3 Non-Local Means

Seja intensidade do pixel i da imagem ruidosa definida por $I_n(i) = I_o(i) + \eta(i)$, onde $I_o(i)$ é imagem original, livre de ruído e $\eta(i) \sim \mathcal{N}(0, \sigma^2)$ é o ruído presente na imagem. A imagem restaurada $\hat{I}(i)$ é dada por (KHELLAH, 2013):

$$\hat{I}(i) = \sum_{j \in I_n} w(i, j) \cdot I_n(j) \quad (2.4)$$

Onde $w(i, j)$ quantifica a similaridade entre duas regiões, N_i e N_j , de tamanho rxr (tipicamente, $r = 7, 9$) centradas em i e j , respectivamente. A Equação 2.4 é aplicada apenas a uma determinada vizinhança S_i de tamanho $M \times M$ (tipicamente, $M = 21$) em torno do pixel central i . Esta versão do algoritmo é também conhecida como *NL-means* janelado. A função de pesos $w(i, j)$ é computada para cada um dos píxeis i da imagem, de acordo com a equação:

$$w(i, j) = \frac{1}{Z(i)} \cdot e^{-\frac{\|v(N_i) - v(N_j)\|_{2,a}^2}{h^2}} \quad (2.5)$$

Onde $v(N_i)$ e $v(N_j)$ são os vetores que contém os as intensidades dos píxeis das vizinhanças N_i e N_j , respectivamente. A norma do vetor computa a distância Euclidiana ponderada por uma distribuição Gaussiana de desvio-padrão a entre as vizinhanças. O parâmetro de suavidade h controla a extensão do cálculo de médias, e tipicamente $h = \sigma$. Dessa forma, quando a variância do ruído é alto, a função de pesos será majoritariamente determinada por h , e os pesos computados não refletirão de maneira adequada a similaridade entre as regiões, e pesos demasiadamente altos serão atribuídos para quase todas as regiões dentro da janela de busca S_i . O resultado desta filtragem, para ruídos de alto valor de variância, \hat{I} será aproximadamente a média das intensidades de todos os píxeis contidos em S_i , ou seja, o resultado da filtragem será uma imagem borrada, principalmente nas regiões de alta frequência. (KHELLAH, 2013).

Na Equação 2.5, $Z(i)$ é um termo que normaliza a função, ou seja, $\sum_j w(i, j) = 1$. A função em Equação 2.4 computa a similaridade entre dois píxeis i e j quaisquer de uma imagem baseada em suas vizinhanças, N_i e N_j , respectivamente (KHELLAH, 2013).

2.4.4 Non-Local Dual Image Denoising

2.4.5 Filtro de Wavelet

2.4.6 Dual Domain Image Denoising

O filtro DDID propõe-se como uma alternativa que produz resultados semelhantes ao BM3D (Dabov et al., 2007), considerado o estado da arte no que diz respeito à filtragem de ruído em imagens, mas com uma implementação muito mais simples (Knaus; Zwicker, 2013).

Tratando-se de um método de filtragem híbrida, este combina abordagens presentes na literatura em cada um dos domínios: no domínio espacial, utiliza-se o filtro bilateral, que preserva

os objetos de alto contraste, como arestas, mas não mantém as regiões de baixo contraste, como texturas; no domínio da transformada, é utilizada uma combinação de Transformada de Fourier de Tempo curto (do inglês, *Short-Time Fourier Transform*) e o algoritmo de *Wavelet SHrinkage*, combinação esta que resulta em boa preservação de detalhes, mas sofre distorções de *ringing* para transições abruptas (Knaus; Zwicker, 2013).

Inicialmente, tem-se o modelo da imagem ruidosa, y , dado por:

$$y = x + \eta \quad (2.6)$$

onde x é a imagem original, livre de ruído, e η é o ruído de variância constante σ^2 presente na imagem observada. A imagem é então decomposta em duas camadas, uma de alto contraste (\tilde{s}) e outra de baixo contraste (\tilde{S}), que serão filtradas separadamente e então somadas para se obter a aproximação da imagem original \tilde{x} . A imagem de alto contraste é obtida a partir da aplicação do filtro bilateral, e a imagem de baixo contraste corresponde ao resíduo dessa mesma filtragem. A imagem resultante da filtragem bilateral já possui tratamento de ruído, bastando então realizar a filtragem da imagem de baixo contraste no domínio da transformada usando a técnica de *Wavelet Shrinkage*. A aproximação da imagem original \tilde{x} é, portanto, obtida pela soma das camadas (Knaus; Zwicker, 2013):

$$\tilde{x} = \tilde{s} + \tilde{S} \quad (2.7)$$

Este procedimento apenas filtra uma única banda de amplitude da imagem. O filtro bilateral protege grandes amplitudes da imagem, enquanto que o *Wavelet Shrinkage* corta pequenas amplitudes. Dessa forma, apenas amplitudes nessa faixa são filtradas, o que requer que seja utilizado um método iterativo, iniciando-o com a imagem ruidosa y , e o resultado de cada iteração é utilizado como guia da próxima iteração. As etapas do método são descritas para uma iteração abaixo.

2.4.6.1 Filtragem no Domínio Espacial: Filtro Bilateral

2.4.6.2 Filtragem no Domínio da Transformada

Na segunda etapa do algoritmo, será realizada a preparação do sinal para se aplicar a técnica de *Wavelet Shrinkage*, e, para isso, obter-se-á uma imagem de baixo contraste e então aplicando-se o STFT. Os coeficientes resultantes desta etapa são definidos pelas equações:

$$G_{p,f} = \sum_{q \in \mathcal{N}_p} e^{-\frac{i2\pi(q-p) \cdot f}{2r+1}} \cdot k_{p,q} \cdot (g_q - \tilde{g}_p) \quad (2.8)$$

$$S_{p,f} = \sum_{q \in \mathcal{N}_p} e^{-\frac{i2\pi(q-p) \cdot f}{2r+1}} \cdot k_{p,q} \cdot (y_q - \tilde{s}_p) \quad (2.9)$$

Como indicam as Equações 2.8 e 2.9, as imagens em baixo contraste são obtidas subtraindo-se os resultados da filtragem bilateral, \tilde{g}_p e \tilde{s}_p de g_p e y_p , e multiplicando o resultado pelo *kernel* definido em Equação 2.3. A STFT consiste de uma Transformada Discreta de Fourier (DFT) precedida de uma multiplicação do sinal por uma função de janelamento, a fim de se evitar artefatos nas fronteiras (Allen, 1977). Utiliza-se uma DFT não unitária para se realizar a transição para o domínio da frequência. Os coeficientes $G_{p,f}$ e $S_{p,f}$ são definidos para o conjunto $f \in \mathcal{F}_p$, sendo \mathcal{F}_p a janela de frequências de mesmo tamanho de \mathcal{N}_p . Assumindo que o *kernel* bilateral $K_{p,q}$ é livre de quaisquer ruídos, a variância dos coeficientes de Fourier ($G_{p,f}$ e $S_{p,f}$) é definida por (Knaus; Zwicker, 2013):

$$\sigma_{p,f}^2 = \sigma^2 \cdot \sum_{q \in \mathcal{N}_p} k_{p,q}^2 \quad (2.10)$$

2.4.6.3 Domínio da Frequência: Wavelet Shrinkage

Por fim, aplica-se o algoritmo denominado *Wavelet Shrinkage*, o qual consiste na atenuação dos coeficientes de Fourier $S_{p,f}$ através de pesos, que, no caso deste algoritmo, são bastante similares aos pesos definidos para o *kernel* fotométrico (Equação 2.3). No caso do *kernel* fotométrico, estes foram projetados tais que retenha-se o ruído de média próxima a zero e descarte a tendência induzida pelo sinal. No entanto, para os fatores de *Wavelet Shrinkage*, deseja-se o oposto: deve-se manter o sinal e descartar o ruído. Portanto, toma-se o recíproco da distância Euclidiana, isto é, $\frac{\sigma_f^2}{|G_{p,f}|^2}$ (Knaus; Zwicker, 2013). Os coeficientes do domínio da frequência são, desta forma, definidos por:

$$\tilde{S}_p = \frac{1}{|\mathcal{F}_p|} \cdot \sum_{f \in \mathcal{F}_p} K_{p,f} \cdot S_{p,f} \quad (2.11)$$

onde os fatores de *shrinkage* são definidos por:

$$K_{p,f} = e^{-\frac{\gamma_f \cdot \sigma_{p,f}^2}{|G_{p,f}|^2}} \quad (2.12)$$

Da mesma forma que no caso do filtro bilateral (Equação 2.3), os coeficientes $K_{p,f}$ são definidos a partir do guia espectral $G_{p,f}$, e o parâmetro γ_f possui a função análoga a γ_r no caso do filtro bilateral.

2.4.7 Data Adaptive Dual Domain Denoising

Conhecido pela sigla DA3D (Pierazzo M. E. Rais, 2015), este método se propõe como uma “última etapa de filtragem”, recebendo como entradas uma imagem ruidosa e uma “imagem-guia”, esta última sendo o resultado da aplicação de algum outro algoritmo estado-da-arte. Nesse quesito, o DA3D se atua de maneira com o algoritmo DDID (ver subseção 2.4.2). Mas

diferentemente do DDID, o DA3D realiza o processamento apenas em uma fração dos fragmentos, que são agrupados ao invés de se considerar apenas o pixel central. Outra característica deste algoritmo é seleção dinâmica dos fragmentos, que são majoritariamente concentrados em regiões da imagem com maior número de detalhes. Dessa forma, o custo computacional é reduzido em áreas uniformes da imagem, o que acelera consideravelmente o processo. O processamento de apenas uma fração dos fragmentos e a diminuição do custo computacional são características que contribuem para a possibilidade de se utilizar fragmentos muito maiores do que o que é comumente encontrado na literatura (64x64 píxeis), característica esta que é importante para melhora na qualidade da filtragem, outra característica proposta por (Pierazzo M. E. Rais, 2015)

A função de peso apresentada no algoritmo DDID (Equação 2.3) seleciona píxeis de intensidades similares, processando a imagem através de camadas “constantes”. Contudo, este modelo não é adequado para imagens contendo gradientes ou sombreamentos, já que uma mesma região “suave” pode ser separada em várias regiões diferentes.

A função de peso do filtro bilateral (Equação 2.3) seleciona píxeis do bloco com intensidades similares. Dessa forma, o passo “esparso” do DDID funciona processando partes da imagem que são constantes por partes, considerando a imagem como sendo a composição de várias camadas “constantes”.

2.4.8 Block Matching and 3D Filtering

Considerado o estado da arte no campo de filtragem de ruídos em imagens, o algoritmo de *Block-matching and 3D Filtering* combina o agrupamento de fragmentos da imagem ruidosa em estruturas de dados tridimensionais, processo chamado de *Block-matching* e a *Collaborative filtering* (ou filtragem colaborativa), que processa de forma adequada os grupos de blocos de uma imagem. Neste último, compreende-se três passos consecutivos: transformada 3D aplicada a um determinado grupo, *shrinkage* do espectro no domínio da transformada e transformada 3D inversa. Dessa forma, obter-se-á um vetor de matrizes 2D das estimativas de cada um dos fragmentos pertencentes ao grupo (Dabov et al., 2007).

Assim, graças à similaridade dos blocos do grupo, a transformada resulta em uma representação bastante espaçada do sinal, possibilitando a filtragem do ruído por *shrinkage*. A filtragem colaborativa é capaz de identificar e preservar desde os detalhes mais finos presentes no grupo até os artefatos únicos de cada bloco, e os resultados experimentais presentes em (Dabov et al., 2007) mostram que este algoritmo atinge níveis excelentes de performance, tanto em termos quantitativos (Relação sinal-ruído de pico, ou PSNR - ver subseção 2.7.1) quanto em termos qualitativos (avaliação visual das imagens).


Cada uma das etapas do algoritmo BM3D serão detalhadas a seguir.

2.4.8.1 *Block-matching*

O conceito de agrupamento é a criação de arranjos de dados compostos por diferentes fragmentos 2D de uma imagem que são semelhantes dentro de um critério previamente determinado. Dessa forma, obtém-se um arranjo tridimensional chamado de “grupo”, o que permite utilizar métodos de filtragem com mais dimensões, isto é, filtragem 3D, que se utiliza da similaridade (ou correlação) entre os fragmentos para se estimar o seu valor real.

Diferentemente do que se propõe em muitos métodos de agrupamento (MACQUEEN et al., 1967), (KOHONEN, 1997), (HÖPPNER et al., 1999), etc., o *Block-matching* não resulta em grupos necessariamente disjuntos: neste método, tem-se como objetivo agrupar fragmentos similares ao fragmento de referência dado. A dissimilaridade, entre um **fragmento-candidato** e o **fragmento-referência** de um grupo é determinada por métricas de distância, que se menores que um predeterminado limiar, são agrupadas. Qualquer fragmento da imagem pode ser utilizado como **fragmento-referência** e, portanto, pode ser utilizado para a criação de um grupo (Dabov et al., 2007). A Figura 1 ilustra o processo de *Block-matching* a partir de diferentes blocos-referência.

Figura 1 – Ilustração de *Block-matching* para três diferentes fragmentos de imagem. Em vermelho marcados com um “R”, são os fragmentos-referência; em azul, os respectivos fragmentos semelhantes.



Fonte: [Tampere University of Technology - Institute of Signal Processing](#). Acessado em 16 de novembro de 2019.

2.4.8.2 *Collaborative Filtering* e *shrinkage* no domínio da transformada

Admitindo-se os grupos já formados através do *Block-matching*, dado um grupo de n blocos, obtém-se uma estimativa para cada bloco, as quais são obtidas através de contribuições de todos os fragmentos do grupo, e por isso se utiliza o termo “colaborativo”. Realiza-se, dessa forma, a média dos pixels de cada bloco na mesma posição relativa que, no caso ideal, os blocos agrupados possuem similaridade perfeita, o que produz um resultado equivalente à filtragem por média de aquisições dentro do bloco. Como todos os blocos do grupo são idênticos, o resultado do processo produz blocos estimados não enviesados, e o erro final destes blocos é

devido somente à variância residual, inversamente proporcional ao número de blocos do grupo. Para imagens naturais, os grupos não são idênticos, o que resulta em blocos enviesados, que contribuem fortemente para o erro total da imagem estimada (Dabov et al., 2007).

Para corrigir este problema, realiza-se uma transformação linear, seguida de um *shrinking* nos coeficientes desta, de forma a atenuar o ruído. Por fim, realiza-se a transformada inversa, obtendo-se uma estimativa de cada um dos blocos do grupo. Com relação à transformação linear a ser realizada no grupo, assumindo-se um grupo $d+1$ -dimensional de fragmentos similares, deve-se escolher uma transformada tal que seja também $d+1$ -dimensional (Dabov et al., 2007).

Este procedimento é especialmente eficiente no caso de imagens naturais, caracterizadas tanto pela correlação intra-fragmentos quanto pela correlação inter-fragmentos dentro de um grupo, e produz uma representação *sparse* do sinal real, e, portanto, torna o processo de *shrinkage* muito eficaz na atenuação de ruído, assim como na preservação do sinal original. Na Figura 1, pode-se notar exemplos claros de como esses padrões de similaridade ocorrem em imagens naturais, e que, portanto, assumir a presença de tais estruturas neste tipo de imagens é uma suposição bastante realista (Dabov et al., 2007).

2.5 Descritores de Textura

2.5.1 Haralick (GLCM)

2.5.2 Local Binary Pattern

O LBP é um descritor de texturas que computa características de textura a partir dos níveis de cinza de uma imagem. para cada pixel da imagem, é atribuído um valor de LBP, que leva em consideração as distâncias (isto é, diferença entre níveis de cinza) entre o pixel central e seus vizinhos, computando todas as distâncias dos vizinho e transformando-as em um valor binário.

Assim, seja o pixel central c de uma vizinhança de raio R com P píxeis vizinhos, enumerados de 0 a $P-1$. Cada pixel p possui nível de cinza $g(p)$. Assim, o valor de LBP para o pixel central dessa vizinhança será (KHELLAH, 2013):

$$LBP_{P,R}(c) = \sum_{p=0}^{P-1} s(g_p - g_c) \cdot 2^p \quad (2.13)$$

Onde:

$$g_y \equiv g(p = y) \quad (2.14)$$

no qual a função $s(x)$ é uma função que determina se o pixel p possui um nível de cinza

maior ou menor que o pixel central, isto é, uma função degrau unitário:

$$s(x) = \begin{cases} 1 & , \text{ se } x \geq 0 \\ 0 & , \text{ se } x < 0 \end{cases} \quad (2.15)$$

O valor de P é determinado de acordo com o valor R . Por exemplo, para $R = 1$, $P = 8$; para $R = 2$, $P = 16$. O número de possíveis valores de $LBP_{P,R}$ é igual a 2^P . Para uma imagem i de dimensões $M \times N$, determina-se o valor de LBP para cada pixel de coordenadas $p_{i,j} = (i, j)$ da imagem. Pode-se então representar a imagem inteira por um histograma H dado por:

$$H_k(I) = \sum_{i=1}^N \sum_{j=1}^M f(LBP_{R,P}(p_{i,j}), k) \quad , \text{ onde } k \in [0, K] \quad (2.16)$$

Onde K é o máximo valor de $LBP_{R,P}(c)$, e $f(x)::$

$$f(x, y) = \begin{cases} 1 & , \text{ se } x = y \\ 0 & , \text{ cc.} \end{cases} \quad (2.17)$$

2.5.3 Local Mapped Pattern

2.6 Combinações de Filtros de Ruído e Descritores de Textura

2.6.1 NLM + LBP

Uma das principais deficiências observadas no algoritmo *Non-local Means* (BUADES; COLL; MOREL, 2005) é o alto grau de borramento o qual este está sujeito, principalmente em casos de ruídos muito intensos. Isso ocorre graças ao fato de que o algoritmo incorpora pesos exagerados, que não necessariamente refletem de maneira correta a similaridade entre as regiões de um determinado pixel. Dessa forma, conforme o ruído é maior, seu valor pós-processado será aproximadamente a média de praticamente todos os pixels na região de busca, e, portanto, causará forte suavização de arestas e o efeito de borramento – este último muito mais perceptível quando se observa regiões pequenas de alta frequência (KHELLAH, 2013).

Nesse contexto, KHELLAH propõe uma nova técnica para processamento de ruído em imagens com o objetivo de transpor este problema. O método proposto consiste na alteração da função de pesos, de tal forma que esta leve em conta também informações de similaridade entre as regiões da imagem. Para isso, propõe-se a incorporação do *Local Binary Pattern*, um descritor de textura muito utilizado nas mais variadas aplicações de processamento de imagem e visão computacional.

2.6.1.1 *Non-local Means*2.6.1.2 *Local Binary Pattern (LBP)*2.6.1.3 *Método Proposto – Utilização de função de pesos baseada em LBP*

Neste algoritmo, o histograma da [Equação 2.16](#) é considerado para uma região quadrada L , com lado l , em torno de cada pixel da imagem original.

Baseado na proposta do LBP, como discutido anteriormente (Equações 2.13 até 2.17), propõe-se uma função de pesos dada por:

$$w(i, j)_{LBP} = \frac{1}{Z(p_{i,j})} \cdot e^{-\frac{D(H(L_1) - H(L_2))}{h(S_{p_{i,j}})}} \quad (2.18)$$

Na [Equação 2.18](#), temos $Z(p_{i,j})$, que se trata de um termo de normalização da função. $H(L_1)$ e $H(L_2)$ são os histogramas extraídos de duas regiões distintas L_1 e L_2 . $D(\cdot, \cdot)$ refere-se à métrica qui-quadrática de dissimilaridade usada para comparar histogramas, dada por (KHELLAH, 2013):

$$D(H(L_1), H(L_2)) = \sum_{n=1}^B \frac{[H_n(L_1) - H_n(L_2)]^2}{H_n(L_1) + H_n(L_2)} \quad (2.19)$$

Onde B é o **número de níveis de cinza de cinza total do histograma**, e $H_n(L_1)$ e $H_n(L_2)$ são os valores do histograma para o n -ésimo valor de intensidade em L_1 e L_2 , respectivamente.

Além disso, o parâmetro de atenuação $H(S_{p_{i,j}})$ da [Equação 2.18](#) varia de acordo com a suavidade das regiões subjacentes onde a janela de busca $S_{p_{i,j}}$ está localizada (centrada no pixel $P_{i,j}$). A suavidade da região é estimada a partir do desvio padrão amostrado de todas as distâncias de similaridade obtidas pela [Equação 2.19](#) entre a região de referência (centrada em $P_{i,j}$) e todas as outras regiões dentro da janela de busca $S_{p_{i,j}}$ (KHELLAH, 2013).

2.7 Métricas de Avaliação


2.7.1 *Peak of Signal-to-Noise-Ratio*

3 MATERIAIS E MÉTODOS

3.1 Banco de Imagens

Para validação dos resultados encontrados na teoria, comparação entre os métodos e testes das propostas do trabalho, definiu-se um banco de imagens padrão. O banco de imagens utilizado foi o “*Brodatz Texture Rotation Dataset*”, composta de 32 imagens de texturas em escala de cinza, provenientes de [BRODATZ](#), que foram adquiridas novamente, em diferentes orientações, isto é, em diferentes rotações em relação ao sensor de aquisição. A [Figura 2](#) exibe as imagens-padrão utilizadas até o momento.

Figura 2 – Imagens utilizadas para validação dos filtros propostos.



Fonte: “*Brodatz Texture Rotation Dataset*”. Acessado em 22 de novembro de 2019.

A utilização de padrões de textura como os mostrados na [Figura 2](#) são extremamente úteis neste projeto, uma vez que o principal objetivo deste é garantir a preservação de texturas no processamento de ruído.

3.2 Validação de Métodos da Literatura

Para garantir a obtenção de dados confiáveis e que possam ser comparados entre si, para a validação dos resultados descritos na literatura, realizou-se a contaminação em dez amostras diferentes para cada uma das combinações de imagem (conforme [Figura 2](#)) e ruído Gaussiano, utilizados em diferentes valores de variância. Realizou-se então a filtragem independente de cada uma dessas amostras e, para cada uma das combinações, realizou-se a média dos valores de PSNR de cada um dos processos de filtragem, para que a comparação entre os métodos seja feita com base nestas médias.

Nesta primeira etapa do projeto, realizou-se a comparação entre 4 métodos (BM3D, DA3D, DDID e NLDD), cada um avaliado agindo sob diferentes contaminações de ruídos com 6 valores de variância (ou desvio-padrão) diferentes ($\sigma = \{01, 05, 10, 25, 50, 100\}$) aplicados sob 10 amostras diferentes de 4 imagens de texturas distintas (HWC001-120, HWC002-120, HWC011-120 e HWC012-120), totalizando 240 imagens contaminadas e 960 imagens processadas.

Para realizar este processo, utilizou-se o *toolbox* de processamento de imagens do *software* MATLAB, versão 2017b, que já contempla funções para realizar a leitura de arquivos de imagem, contaminação artificial destas com o ruído especificado, dentre outras funções. Além deste *toolbox*, também foram utilizadas as implementações dos filtros para o MATLAB, algumas fornecidas pelos próprios autores, outras implementadas com base em pseudo-código apresentado nos respectivos trabalhos. Os parâmetros de entrada de cada um dos filtros foram ajustados de forma a se obter resultados compatíveis com o encontrado na literatura, validando a comparação entre os métodos.

3.2.1 DA3D - Detalhes de Implementação

Como discutido na subseção 2.4.7, o DA3D é uma proposta de “última etapa de filtragem”, e, desta forma, requer a utilização de algum outro filtro conhecido da literatura antes de ser aplicado. No caso deste trabalho, optou-se por utilizar o filtro de *NL-Bayes* (BUADES; LEBRUN; MOREL, 2012).

3.3 Próximos Passos

Após a implementação e validação dos métodos mencionados na Seção 3.2, tem-se como próxima etapa do trabalho a implementação dos filtros estudados e apresentados na Seção 2.7 que ainda não foram validados, isto é, *Non-Local Dual Image Denoising* e *Local Binary Pattern to Windowed Non-local Means Image Denoising* (Seções 2.4.4 e 2.6.1, respectivamente).

Após a implementação dos métodos referência em filtragem de ruído, deve-se prosseguir com a implementação dos métodos híbridos. Nesta etapa, o principal objetivo é combinar métodos que possivelmente resultarão em uma filtragem melhor do que os resultados observados na literatura ou de alguma forma são interessantes. Como candidatos imediatos a serem testados, tem-se a combinação entre o NLDD de Pierazzo et al. com o LBP, além do NLM-LBP de KHELLAH com o DA3D de Pierazzo M. E. Rais. Tomando como base estes dois métodos híbridos e seus posteriores resultados, poder-se-á identificar novos métodos candidatos.

Para combinar os métodos da forma proposta, o principal desafio é combiná-los de forma que possam ser interligados de maneira coerente, isto é as saídas e entradas de métodos sequenciados sejam coerentes entre si e produzam resultados satisfatórios.

4 RESULTADOS E DISCUSSÃO

4.1 Validação de Métodos da Literatura

4.1.1 Imagens Obtidas

Nesta Seção, são apresentadas algumas imagens que ilustram de forma qualitativa a diferença entre os métodos escolhidos, para as imagens de textura da [Figura 2](#). As Figuras [3](#) até [10](#) mostram a comparação entre os métodos mencionados, para cada uma das imagens escolhidas, em duas intensidades diferentes de ruído – média e alta.

Para as imagens contaminadas com ruído de média intensidade ($\sigma = 25$), pouca diferença é perceptível à olho nu, e os resultados de ambos os métodos são visualmente equivalentes. Para o ruído de alta intensidade ($\sigma = 100$), já nota-se mais claramente um resultado visualmente melhor no caso do BM3D, principalmente para as Figuras [7](#), [8](#) e [9](#), mas a diferença entre os outros dois métodos ainda é quase imperceptível.

Para uma análise mais precisa, comparou-se os valores de PSNR médios – obtidos conforme [subseção 4.1.2](#).

4.1.2 Comparação de PSNR

Comparando os valores de PSNR das Tabelas [1](#) até [4](#) com os resultados originais dos autores – [Dabov et al.](#), [Pierazzo M. E. Rais](#), [Knaus](#); [Zwicker](#) –, conclui-se que os resultados não são incongruentes e, portanto, coerentes.

Os valores de PSNR exibidos nas Tabelas [1](#) até [4](#) referem-se aos valores médios de 10 aquisições independentes realizadas em cada uma das situações, a fim de diminuir a influência de erros aleatórios nos resultados. Analisando os dados obtidos, pode-se ver claramente que o BM3D é majoritariamente o melhor método, apesar de se tratar de um espaço amostral relativamente pequeno. Dessa forma, estes resultados são coerentes com os resultados qualitativos discutidos na [subseção 4.1.1](#), uma vez que ambos indicam a melhor saída do processamento para o mesmo caso.

Figura 3 – Detalhe em HWC001-120 para comparação entre métodos de filtragem, com $\sigma = 25$.




Figura 4 – Detalhe em HWC002-120 para comparação entre métodos de filtragem, com $\sigma = 25$.




Figura 5 – Detalhe em HWC011-120 para comparação entre métodos de filtragem, com $\sigma = 25$.




Figura 6 – Detalhe em HWC012-120 para comparação entre métodos de filtragem, com $\sigma = 25$.




Figura 7 – Detalhe em HWC001-120 para comparação entre métodos de filtragem, com $\sigma = 100$.







Figura 8 – Detalhe em HWC002-120 para comparação entre métodos de filtragem, com $\sigma = 100$.Figura 9 – Detalhe em HWC011-120 para comparação entre métodos de filtragem, com $\sigma = 100$.Figura 10 – Detalhe em HWC012-120 para comparação entre métodos de filtragem, com $\sigma = 100$.

σ	Ruidosa	BM3D	DA3D	DDID
1,00	47,051	47,052	32,340	47,062
5,00	33,774	35,038	31,298	34,787
10,0	28,129	30,864	29,905	30,347
25,0	20,346	26,352	26,379	26,312
50,0	15,057	22,511	22,855	21,981
100,0	10,456	16,648	13,869	14,228

Tabela 1 – Valores de PSNR médio para aquisições em HWC001-120. Os maiores valores para cada tipo de ruído estão em negrito.

σ	Ruidosa	BM3D	DA3D	DDID
1,00	45,958	46,170	35,360	46,071
5,00	32,721	36,298	33,591	35,559
10,0	27,420	32,879	31,812	32,274
25,0	20,213	28,984	28,466	28,799
50,0	14,587	25,363	25,237	25,094
100,0	10,155	19,627	18,503	18,025

Tabela 2 – Valores de PSNR médio para aquisições em HWC002-120. Os maiores valores para cada tipo de ruído estão em negrito.

σ	Ruidosa	BM3D	DA3D	DDID
1,00	47,600	47,623	34,912	47,605
5,00	34,129	36,867	33,493	36,161
10,0	28,133	33,220	31,682	32,568
25,0	20,225	28,725	28,183	28,555
50,0	14,617	25,211	24,908	24,918
100,0	10,161	20,037	17,851	18,331

Tabela 3 – Valores de PSNR médio para aquisições em HWC011-120. Os maiores valores para cada tipo de ruído estão em negrito.

σ	Ruidosa	BM3D	DA3D	DDID
1,00	46,690	46,985	36,591	46,914
5,00	33,428	37,123	34,802	36,421
10,0	28,013	33,591	32,666	33,181
25,0	20,351	29,032	28,684	29,026
50,0	14,962	24,933	24,710	24,626
100,0	10,380	19,375	18,379	18,087

Tabela 4 – Valores de PSNR médio para aquisições em HWC012-120. Os maiores valores para cada tipo de ruído estão em negrito.

REFERÊNCIAS

- Allen, J. Short term spectral analysis, synthesis, and modification by discrete fourier transform. **IEEE Transactions on Acoustics, Speech, and Signal Processing**, v. 25, n. 3, p. 235–238, June 1977.
- BRODATZ, P. **Textures: a photographic album for artists and designers**. [S.l.]: Dover Pubns, 1966.
- BUADES, A.; COLL, B.; MOREL, J. M. A review of image denoising algorithms, with a new one. **Multiscale Modeling & Simulation**, v. 4, n. 2, p. 490–530, 2005. Disponível em: <https://doi.org/10.1137/040616024>.
- BUADES, A.; LEBRUN, M.; MOREL, J. Implementation of the non-local bayes image denoising algorithm. **Image Processing On Line**, 2012.
- Dabov, K. et al. Image denoising by sparse 3-d transform-domain collaborative filtering. **IEEE Transactions on Image Processing**, v. 16, n. 8, p. 2080–2095, Aug 2007.
- HÖPPNER, F. et al. **Fuzzy cluster analysis: methods for classification, data analysis and image recognition**. [S.l.]: John Wiley & Sons, 1999.
- KHELLAH, F. Application of local binary pattern to windowed nonlocal means image denoising. In: SPRINGER. **International Conference on Image Analysis and Processing**. [S.l.], 2013. p. 21–30.
- Knaus, C.; Zwicker, M. Dual-domain image denoising. In: **2013 IEEE International Conference on Image Processing**. [S.l.: s.n.], 2013. p. 440–444. ISSN 1522-4880.
- KOHONEN, T. Exploration of very large databases by self-organizing maps. In: IEEE. **Proceedings of International Conference on Neural Networks (ICNN'97)**. [S.l.], 1997. v. 1, p. PL1–PL6.
- MACQUEEN, J. et al. Some methods for classification and analysis of multivariate observations. In: OAKLAND, CA, USA. **Proceedings of the fifth Berkeley symposium on mathematical statistics and probability**. [S.l.], 1967. v. 1-14, p. 281–297.
- Pierazzo M. E. Rais, J. M. M. G. F. N. Da3d: Fast and data adaptive dual domain denoising. In: **2015 IEEE International Conference on Image Processing (ICIP)**. [S.l.: s.n.], 2015. p. 432–436.
- Pierazzo, N. et al. Non-local dual image denoising. In: **2014 IEEE International Conference on Image Processing (ICIP)**. [S.l.: s.n.], 2014. p. 813–817.

Apêndices

APÊNDICE A – EXEMPLO DE APÊNDICE

Anexos

ANEXO A – EXEMPLO DE ANEXO